UNIVERSIDAD CATOLICA BOLIVIANA ¨SAN PABLO”

CASO 6 –- E-COMMERCE LOGISTICS OPTIMIZATION (LOGISTICA/RETAIL)

INTEGRANTES

Jean Marco Fernandez Silva

Sergio Alejandro Arias Mayta

Marvin Larry Mollo Ramirez

Jaime Ignacion Huaycho Clavel

Sergio Alexander Mendoza Choque

MATERIA

Machine Learning

AÑO

2026

Marco Metodológico: CRISP-DM

Este proyecto sigue la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), el estándar de facto para proyectos de ciencia de datos. CRISP-DM provee una guía estructurada que va desde la comprensión del negocio hasta el despliegue del modelo, garantizando trazabilidad, claridad de entregables y puntos de control por fase.

1. Descripción del Problema y Contexto del Negocio - Business Understanding

1.1. Contexto Operativo

La base de datos histórica disponible, compuesta por 10,999 registros de envíos, revela patrones críticos sobre el comportamiento logístico y la satisfacción del cliente. Variables como el número de llamadas a atención al cliente (Customer Care Calls) y la calificación del servicio (Customer Rating) sugieren una correlación directa entre la eficiencia de la entrega y la percepción de marca.

Actualmente, la empresa opera bajo un modelo reactivo: los problemas se gestionan una vez que el retraso ha ocurrido. El objetivo de este proyecto es transicionar hacia un modelo predictivo y proactivo mediante técnicas de Machine Learning, permitiendo a la gerencia tomar decisiones basadas en datos antes de que los incidentes impacten al cliente final.

1.2. Definición de los Objetivos del Proyecto

El proyecto se divide en dos flujos de trabajo analíticos complementarios, diseñados para abordar tanto la gestión financiera del inventario como la eficiencia operativa de los envíos:

A. Objetivo de Regresión: Predecir el costo del producto Desarrollar modelos de regresión para estimar el costo del producto basándose en características logísticas y del cliente.

B. Objetivo de Clasificación: Predecir Entregas a Tiempo Construir modelos de clasificación binaria para determinar si un envío llegará a tiempo o experimentará retrasos.

C. Objetivo de análisis: Identificar Patrones Descubrir patrones ocultos en entregas y desempeño logístico para optimizar operaciones y mejorar la satisfacción del cliente.

2. Comprensión de los Datos - Data Understanding

2.1. Inspección Inicial del Dataset

El dataset contiene 10,999 observaciones y 12 variables. La estructura del dataset es la siguiente:

Variable	Tipo	Descripción
ID	int64	Identificador (eliminado)
Warehouse_block	object	Bloque de almacén (A–F)
Mode_of_Shipment	object	Modo de envío
Customer_care_calls	int64	Llamadas a soporte
Customer_rating	int64	Calificación del cliente
Cost_of_the_Product	int64	Costo del producto (target regresión)
Prior_purchases	int64	Compras previas
Product_importance	object	Importancia del producto
Gender	object	Género (eliminado)
Discount_offered	int64	Descuento ofrecido (transformado)

Weight_in_gms	int64	Peso en gramos
Reached.on.Time_Y.N	int64	Target clasificación

2.2. Distribución del Target de Clasificación

El dataset presenta un desbalance moderado en la variable objetivo Reached.on.Time_Y.N:

- Clase 1 (No llegó a tiempo): 6,563 registros (59.7%)
- Clase 0 (Llegó a tiempo): 4,436 registros (40.3%)

2.3. Análisis de Correlación

Se generó una matriz de correlación sobre las variables numéricas del dataset. Los hallazgos principales incluyen:

- La variable Discount_offered muestra la correlación más alta con el target de clasificación.
- Las demás variables numéricas presentan correlaciones débiles entre sí, indicando poca multicolinealidad.
- La variable Prior_purchases presenta outliers justificados por el modelo de negocio.

2.4. Hallazgos Clave del EDA

- El análisis de densidad de Discount_offered vs. Reached.on.Time_Y.N revela que descuentos superiores al 10% muestran un punto de inflexión en la distribución de entregas a tiempo.
- La distribución del costo del producto vs. llamadas de atención al cliente muestra que productos más caros generan más llamadas, con outliers en productos baratos que alcanzan hasta 6 llamadas.
- El modo de envío predominante es Ship con 7,462 registros (67.8%).
- Warehouse_block F concentra el 33.3% de los envíos (3,666 registros).

3. Análisis Exploratorio de Datos (EDA) - Data Understanding

3.1 Limpieza de datos

Se aplicaron las siguientes acciones de limpieza:

- Eliminación de la columna ID (identificador sin valor predictivo)
- Eliminación de la columna Gender (no relevante para el modelo).
- Verificación de valores nulos: ninguno encontrado
- Verificación de duplicados: dataset limpio

3.2. Construcción de Pipelines

Para garantizar la reproducibilidad y evitar data leakage, se construyeron pipelines que integran el preprocesamiento y los modelos:

1) **Pipeline de Regresión (Target: Cost_of_the_Product)**
    - **Preprocesamiento:** StandardScaler + PolynomialFeatures(degree=2) para variables numéricas
    - **Modelo base:** Ridge(alpha=1.0) con regularización L2.
    - **Justificación:** PolynomialFeatures captura la relación no lineal entre costo y llamadas de atención al cliente identificada en el EDA.
    - **Regularización:** Ridge mitiga el riesgo de overfitting ante la posible multicolinealidad de las variables dummy.
2) **Pipeline de Clasificación (Target: Reached.on.Time_Y.N)** Se construyeron dos pipelines para modelos de clasificación:
    - **Pipeline 1 - Árbol de Decisión:** Feature engineering (high_discount) → OrdinalEncoder + OneHotEncoder + StandardScaler → DecisionTreeClassifier
    - **Pipeline 2 - Modelo Optimizado:** Misma estructura de preprocesamiento con DecisionTreeClassifier ajustado
    - **Configuración común:** max_depth=10, min_samples_split=20, min_samples_leaf=10, criterion="entropy", class_weight="balanced"
    - **Ventaja del pipeline:** Garantiza que las transformaciones se apliquen de forma consistente en entrenamiento y predicción, evitando data leakage.

3.3. Ingeniería de Características

Se creó la variable high_discount como transformación de Discount_offered:

- high_discount = 1 si Discount_offered > 10, de lo contrario 0.
- Esta transformación reduce el ruido y captura el punto de inflexión identificado en el EDA.

3.4. Codificación de Variables Categóricas

1) **OneHotEncoder (Variables Nominales)**

Aplicado a variables sin orden intrínseco:

- Warehouse_block: Bloques A, B, C, D, E, F → vectores binarios
- Mode_of_Shipment: Ship, Flight, Road → vectores binarios

2) **OrdinalEncoder (Variable Ordinal)**

Aplicado a Product_importance capturando la jerarquía de negocio:

- low (0) → 5,297 registros
- medium (1) → 4,754 registros
- high (2) → 948 registros

3.5. División de Datos

Los datos se dividieron en conjuntos de entrenamiento y prueba:

- **Para Clasificación:** 80% entrenamiento (8,799 muestras) - 20% prueba (2,200 muestras)
- **Para Regresión:** 80% entrenamiento (8,799 muestras) - 20% prueba (2,200 muestras)

4. Modelado - Modeling

4.1. Entrenamiento del Modelo de Regresión

El pipeline de regresión Ridge se entrenó sobre el conjunto de entrenamiento (8,799 muestras) utilizando las siguientes variables predictoras:

- Variables numéricas: Customer_care_calls, Discount_offered, Weight_in_gms, Prior_purchases.
- Variables categóricas: Warehouse_block, Mode_of_Shipment, Product_importance.
- Variable derivada: high_discount (creada mediante feature engineering).

4.2. Entrenamiento de los Modelos de Clasificación

Se entrenaron dos modelos de clasificación sobre el conjunto de entrenamiento (8,799 muestras):

4.2.1 Árbol de Decisión Base

Primer modelo con configuración balanceada para capturar ambas clases de forma equitativa.

4.2.2 Modelo Optimizado

Segundo modelo con los mismos hiperparámetros pero optimizado para maximizar el recall de la clase minoritaria (entregas a tiempo).

5. Evaluación de los Modelos - Evaluation

5.1. Evaluación del Modelo de Regresión

Métricas obtenidas sobre el conjunto de prueba:

Modelo	MSE	RMSE	R^2
Ridge (α=1.0)	~1,646	~40.58	0.11

Análisis de Métricas de Rendimiento:

R-squared (R^2): 0.11

El coeficiente de determinación indica que el modelo explica únicamente el 11% de la varianza del costo del producto. Desde una perspectiva estadística, esto significa que el 74% restante de la variabilidad del precio depende de factores que no están capturados en nuestras variables independientes. Un valor de 0.11 confirma que existe una relación débil entre los datos logísticos y el valor monetario del artículo.

Root Mean Squared Error (RMSE): 40.58

La raíz del error cuadrático medio penaliza los errores de gran magnitud. En este contexto, un RMSE de 40.58 señala que la desviación típica de los errores de predicción es de aproximadamente 40.58 USD. Dado que la mayoría de los productos tienen precios en un rango de 100 a 300 USD, este margen de error es considerablemente alto, afectando la confiabilidad del modelo en un entorno de producción.

5.2. Evaluación de los Modelos de Clasificación

Árbol de Decisión

Métrica	Clase 0 (A tiempo)	Clase 1 (Retraso)	Global
Accuracy	—	—	67.94%
Precision	0.56	0.79	0.70 (weighted)
Recall	0.77	0.59	0.66 (weighted)
F1-Score	0.65	0.67	0.67 (weighted)

Conclusiones del Modelo de Árbol de Decisión:

El modelo de Árbol de Decisión alcanzó una precisión de aproximadamente 66% en el conjunto de prueba. Presenta un recall de 0.77 para la clase 0 (no llegó a tiempo), lo que indica que es capaz de identificar correctamente el 77% de los casos reales de retrasos. Esto es deseable en escenarios donde identificar los retrasos es crítico, pero a costa de una menor precisión (0.56) para esta clase. Es un modelo interpretable, pero su rendimiento general es moderado.

Random Forest

Métrica	Clase 0 (A tiempo)	Clase 1 (Retraso)	Global
Accuracy	—	—	68%
Precisión	0.57	0.90	0.78 (weighted)
Recall	0.91	0.52	0.68 (weighted)

F1-Score	0.70	0.63	0.66 (weighted)

Área Bajo la Curva (AUC):

El AUC para el modelo fue de 0.75, lo que indica una buena capacidad de discriminación general del modelo entre las dos clases.

Conclusiones Comparativas de los Modelos de Clasificación:

Ambos modelos muestran un rendimiento moderado en la clasificación de si un envío llegó a tiempo o no. El modelo implementado con el nombre "Random Forest" (aunque utiliza DecisionTreeClassifier) es ligeramente superior en términos de precisión general (68% vs 66%) y ofrece un recall notablemente alto de 0.91 para la clase 0 (no a tiempo). Si el objetivo principal es identificar la mayor cantidad posible de envíos retrasados (minimizando falsos negativos para la clase 0), este modelo es la mejor opción.

Sin embargo, su bajo recall para la clase 1 (llegó a tiempo: 0.52) podría ser un problema si también es crucial identificar correctamente todos los envíos a tiempo. El Árbol de Decisión inicial mantuvo un balance más equitativo entre precisión y recall para ambas clases, aunque a un nivel inferior en general.

6. Interpretación y Decisiones Estratégicas - Deployment

6.1. Interpretación Técnica

Modelos de Regresión:

- El modelo de regresión presenta baja capacidad explicativa ($R^2 \approx 0.11$).
- La regularización Ridge no mejora el desempeño de forma significativa; la limitación es informativa.
- Se requieren variables comerciales adicionales (categoría del producto, marca, tipo) para mejorar la predicción del costo.

Modelos de Clasificación:

- El Árbol de Decisión logra una accuracy del 66% con un recall del 77% para la clase 0 (no llegó a tiempo).
- El segundo modelo obtiene una accuracy del 68% con un recall muy alto (91%) para la clase 0 y una precisión alta (90%) para la clase 1.

- Ambos modelos muestran rendimiento moderado; la elección depende de la prioridad entre minimizar falsos positivos o falsos negativos.
- El AUC de 0.75 indica una capacidad de discriminación aceptable.

6.2. Decisiones Estratégicas

Respecto a la Regresión:

- No se recomienda implementación productiva en el estado actual.
- Se requieren variables comerciales adicionales (tipo de producto, marca, calidad).
- Se recomienda explorar modelos no lineales: Random Forest Regressor o Gradient Boosting.

Respecto a la Clasificación:

- El modelo tiene valor estratégico para anticipar retrasos antes de que impacten al cliente.
- Se recomienda priorizar el recall de la clase de retrasos para proteger la experiencia del cliente.
- El umbral de decisión puede ajustarse para aumentar la detección de retrasos, aceptando más falsas alarmas.
- El modelo con mayor recall (91%) es preferible si se busca minimizar el riesgo de no detectar retrasos.

7. Conclusión

El mayor valor del proyecto se encuentra en el modelo de clasificación, ya que permite anticipar retrasos antes de que impacten al cliente, transformando la gestión logística de un enfoque reactivo a uno predictivo.

Con un recall superior al 91% para la detección de retrasos en el modelo optimizado, y una precisión del 90% en confirmaciones de entrega exitosa, los modelos ofrecen perspectivas complementarias para la toma de decisiones operativas.

El sistema puede identificar la mayoría de los incumplimientos y activar acciones preventivas: priorización de envíos, reasignación de recursos o comunicación anticipada con el cliente. Esto reduce el riesgo reputacional, mejora la experiencia del usuario y optimiza la toma de decisiones operativas basada en datos.

La curva de aprendizaje del modelo de regresión muestra convergencia entre las puntuaciones de entrenamiento y validación, indicando que el modelo ha alcanzado su capacidad máxima con las variables disponibles. Para mejorar el rendimiento, se

requiere enriquecer el dataset con información comercial adicional sobre los productos.

Es Importante destacar una limitación crítica del análisis: El dataset presenta una correlación muy débil entre las variables predictoras y ambos targets (tanto Cost_of_the_Product como Reached.on.Time_Y.N). La matriz de correlación reveló que ninguna variable tiene una asociación fuerte con los objetivos del modelo, siendo discount_offered la única con una correlación moderada respecto a la entrega a tiempo.

Esta falta de correlación explica el bajo rendimiento del modelo de regresión (R^2 = 0.11) y el rendimiento limitado de los modelos de clasificación (accuracy máxima del 68%). Los resultados obtenidos son altamente cuestionables desde una perspectiva predictiva, ya que las variables disponibles no capturan los factores determinantes del costo del producto ni de los retrasos en la entrega.

Para mejorar significativamente el desempeño de los modelos, se requiere:

- Incorporar variables relacionadas con el proceso logístico real (condiciones climáticas, congestión de rutas y capacidad del transporte).
- Incluir características comerciales del producto (categoría, marca, proveedor, país de origen)
- Agregar datos temporales (día de la semana, temporada, fechas festivas)
- Considerar información del cliente (ubicación geográfica, historial de reclamaciones, tipo de suscripción)

Sin estas variables adicionales, cualquier implementación en producción de estos modelos conllevan un riesgo significativo de decisiones empresariales basadas en predicciones poco confiables.