UNIVERSIDAD CATOLICA BOLIVIANA ¨SAN PABLO”

CASO 6 –- E-COMMERCE LOGISTICS OPTIMIZATION (LOGISTICA/RETAIL)

INTEGRANTES

Jean Marco Fernandez Silva

Sergio Alejandro Arias Mayta

Marvin Larry Mollo Ramirez

Jaime Ignacion Huaycho Clavel

Sergio Alexander Mendoza Choque

MATERIA

Machine Learning

AÑO

2026

1. Descripción del Problema y Contexto del Negocio

1.1. Contexto Operativo

La base de datos histórica disponible, compuesta por 10,999 registros de envíos, revela patrones críticos sobre el comportamiento logístico y la satisfacción del cliente. Variables como el número de llamadas a atención al cliente (Customer_care_calls) y la calificación del servicio (Customer_rating) sugieren una correlación directa entre la eficiencia de la entrega y la percepción de marca.

Actualmente, la empresa opera bajo un modelo reactivo: los problemas se gestionan una vez que el retraso ha ocurrido. El objetivo de este proyecto es transicionar hacia un modelo predictivo y proactivo mediante técnicas de Machine Learning, permitiendo a la gerencia tomar decisiones basadas en datos antes de que los incidentes impacten al cliente final.

1.2. Definición de los Objetivos del Proyecto

El proyecto se divide en dos flujos de trabajo analíticos complementarios, diseñados para abordar tanto la gestión financiera del inventario como la eficiencia operativa de los envíos:

A. Objetivo de Regresión: Predecir el costo del producto Desarrollar modelos de regresión para estimar el costo del producto basándose en características logísticas y del cliente.

B. Objetivo de Clasificación: Predecir Entregas a Tiempo Construir modelos de clasificación binaria para determinar si un envío llegará a tiempo o experimentará retrasos.

C. Objetivo de análisis: Identificar Patrones Descubrir patrones ocultos en entregas y desempeño logístico para optimizar operaciones y mejorar la satisfacción del cliente.

2. Preprocesamiento de Datos

En esta fase se preparó el dataset para garantizar la calidad y compatibilidad con los algoritmos de Machine Learning. El pipeline de transformación incluyó los siguientes pasos críticos:

2.1. Limpieza e Inspección Inicial

El dataset Train.csv contiene 10,999 observaciones y 12 variables, según la estructura verificada en el notebook:

Acciones de limpieza aplicadas:

Variable	Tipo	Descripción

ID	int64	Identificador (eliminado)
Warehouse_block	object	Bloque de almacén (A–F)
Mode_of_Shipment	object	Modo de envío
Customer_care_calls	int64	Llamadas a soporte
Customer_rating	int64	Calificación del cliente
Cost_of_the_Product	int64	Costo del producto (target regresión)
Prior_purchases	int64	Compras previas
Product_importance	object	Importancia del producto
Gender	object	Género (eliminado)
Discount_offered	int64	Descuento ofrecido (transformado)
Weight_in_gms	int64	Peso en gramos
Reached.on.Time_Y.N	int64	Target clasificación

- Eliminación de la columna ID (identificador sin valor predictivo).
- Eliminación de la columna Gender (no relevante para el modelo).
- Verificación de valores nulos: isnull().sum() — ninguno encontrado.
- Verificación de duplicados: duplicated().sum() — dataset limpio.
- Ingeniería de características: creación de High_Discount (1 si Discount_offered > 10) para reducir ruido.

2.2. Codificación de Variables Categóricas

OneHotEncoder (Variables Nominales)

Aplicado a variables sin orden intrínseco para evitar que el modelo asume jerarquías falsas:

- Warehouse_block: Bloques A, B, C, D, E, F → vectores binarios.
- Mode_of_Shipment: Ship (7,462), Flight (1,777), Road (1,760).

OrdinalEncoder (Variable Ordinal)

Aplicado a Product_importance capturando la jerarquía de negocio:

- low (0) → 5,297 registros
- medium (1) → 4,754 registros
- high (2) → 948 registros

Justificación: esta codificación permite al modelo entender que una importancia 'alta' tiene mayor magnitud que una 'baja'.

3. Análisis Exploratorio de Datos (EDA)

3.1. Distribución del Target de Clasificación

Clase	Cantidad de Registros
1 — No llegó a tiempo (Retraso)	6,563 (59.7%)
0 — Llegó a tiempo	4,436 (40.3%)

El dataset presenta un desbalance moderado, con más registros de retrasos que de entregas exitosas. Esto fue gestionado mediante estratificación al dividir el dataset.

3.2. Distribución de Variables Clave

- Warehouse_block F concentra el 33.3% de los envíos (3,666 registros).
- El modo de envío predominante es Ship con 7,462 registros (67.8%).
- La variable Prior_purchases presenta outliers justificados por el modelo de negocio.
- La variable Discount_offered fue transformada en High_Discount (umbral: 10) para reducir ruido y mejorar el entrenamiento.

3.3. Análisis de Correlación

Se generó una matriz de correlación sobre el dataset procesado con todas las variables codificadas. La variable Discount_offered fue eliminada tras el EDA por su alta correlación con la variable derivada High_Discount y para evitar redundancia informativa.

4. Modelado

4.1. Estrategia de Regresión (Target: Cost_of_the_Product)

División del dataset: 90% entrenamiento (9,899 muestras) — 10% prueba (1,100 muestras), con estratificación por bins del target continuo.

4.1.1 Regresión Lineal (OLS — Baseline)

Configuración: Mínimos Cuadrados Ordinarios sin penalización, dentro de un Pipeline con StandardScaler. Sirve como referencia de desempeño.

4.1.2 Regresión Ridge (L2)

Configuración: alpha=1.0, penalización L2 sobre los coeficientes. Reduce la varianza contrayendo coeficientes sin anularlos, mitigando el riesgo de overfitting ante la posible multicolinealidad de las variables dummies.

4.1.3 Regresión Lasso (L1)

Configuración: alpha=1.0, max_iter=1000. A diferencia de Ridge, puede anular coeficientes actuando como selector automático de variables. El valor alpha=1.0 resultó en penalización excesiva, sugiriendo que un GridSearchCV podría optimizar el hiperparámetro.

4.2. Estrategia de Clasificación (Target: Reached.on.Time_Y.N)

División del dataset: 85% entrenamiento (9,349 muestras) — 15% prueba (1,650 muestras), con estratificación sobre el target.

4.2.1 Árbol de Decisión

Configuración del Pipeline: StandardScaler + DecisionTreeClassifier con criterio Gini, max_depth=8, min_samples_split=10, min_samples_leaf=10, random_state=42.

4.2.2 Random Forest

Configuración del Pipeline: StandardScaler + RandomForestClassifier con n_estimators=150, max_depth=8, min_samples_split=10, min_samples_leaf=10, max_features=0.5, bootstrap=True, class_weight='balanced', random_state=42.

5. Evaluación de los Modelos

5.1. Evaluación del Modelo de Regresión (Cost_of_the_Product)

Métricas obtenidas sobre el conjunto de prueba (1,100 muestras):

Modelo	MAE	RMSE	R^2
Regresión Lineal (OLS)	36.50	43.87	0.1785
Ridge (L2, α=1.0)	36.50	43.87	≈ 0.1785
Lasso (L1, α=1.0)	36.91	44.11	—

.Análisis: El R^2 de 0.1785 indica que el modelo explica apenas el 17.85% de la variabilidad del costo del producto. La similitud de resultados entre Linear Regression y Ridge confirma que la limitación es informativa (el dataset no contiene variables suficientemente relacionadas con la formación del precio), no de optimización del modelo.

5.2. Evaluación de los Modelos de Clasificación (Reached.on.Time_Y.N)

Árbol de Decisión

Métrica	Clase 0 (A tiempo)	Clase 1 (Retraso)	Global
Accuracy	—	—	67.94%
Precision	0.56	0.93	0.78 (weighted)
Recall	0.94	0.50	0.68 (weighted)
F1-Score	0.70	0.65	0.67 (weighted)

Matriz de Confusión — Árbol de Decisión:

	Pred. 0 (A tiempo)	Pred. 1 (Retraso)
Real 0 (A tiempo)	TN = 627	FP = 38
Real 1 (Retraso)	FN = 491	TP = 494

Random Forest

Métrica	Clase 0 (A tiempo)	Clase 1 (Retraso)	Global
Accuracy	—	—	67.27%
Precision	0.55	0.97	0.80 (weighted)
Recall	0.98	0.46	0.67 (weighted)
F1-Score	0.71	0.63	0.66 (weighted)

Matriz de Confusión — Random Forest:

	Pred. 0 (A tiempo)	Pred. 1 (Retraso)
Real 0 (A tiempo)	TN = 652	FP = 13
Real 1 (Retraso)	FN = 527	TP = 458

6. Interpretación y Decisiones Estratégicas

6.1. Interpretación Técnica

Modelos de Regresión:

- El modelo de regresión presenta baja capacidad explicativa ($R^2 \approx 0.18$).
- La regularización Ridge y Lasso no mejoran el desempeño de forma significativa; la limitación es informativa.
- Se requieren variables comerciales adicionales (categoría del producto, marca, tipo) para mejorar la predicción del costo.

Modelos de Clasificación:

- El Árbol de Decisión logra una accuracy del 67.94% con un recall del 94% para retrasos (Clase 0 en la codificación).
- El Random Forest obtiene una accuracy del 67.27% con una precisión muy alta (97%) para la Clase 1 (llegó a tiempo).
- Ambos modelos muestran rendimiento moderado; la elección depende de la prioridad entre minimizar falsos positivos o falsos negativos.

6.2. Implicaciones de los Errores

Tipo de Error	Árbol de Decisión	Random Forest	Impacto
Falsos Negativos (FN)	491	527	Retrasos no detectados — riesgo reputacional alto
Falsos Positivos (FP)	38	13	Alertas innecesarias — costo operativo menor

6.3. Decisiones Estratégicas

Respecto a la Regresión:

- No se recomienda implementación productiva en el estado actual.
- Se requieren variables comerciales adicionales (tipo de producto, marca, calidad).
- Se recomienda explorar modelos no lineales: Random Forest Regressor o Gradient Boosting.

Respecto a la Clasificación:

- El modelo tiene valor estratégico para anticipar retrasos antes de que impacten al cliente.

- Se recomienda priorizar el recall de la clase de retrasos para proteger la experiencia del cliente.
- El umbral de decisión puede ajustarse para aumentar la detección de retrasos, aceptando más falsas alarmas.
- El Random Forest es preferible si se busca minimizar falsas promesas al cliente (FP = 13 vs 38 del árbol).

7. Conclusión

El mayor valor del proyecto se encuentra en el modelo de clasificación, ya que permite anticipar retrasos antes de que impacten al cliente, transformando la gestión logística de un enfoque reactivo a uno predictivo.

Con un recall superior al 94% para la detección de retrasos (Árbol de Decisión) y una precisión del 97% en confirmaciones de entrega exitosa (Random Forest), los modelos ofrecen perspectivas complementarias para la toma de decisiones operativas.

El sistema puede identificar la mayoría de los incumplimientos y activar acciones preventivas: priorización de envíos, reasignación de recursos o comunicación anticipada con el cliente. Esto reduce el riesgo reputacional, mejora la experiencia del usuario y optimiza la toma de decisiones operativas basada en datos.